

APRENDIZAJE AUTOMATICO PROFUNDO (DEEP LEARNING)



- **Profesora : Dra. Laura Lanzarini**

- Temas: Redes Neuronales y Técnicas de Optimización
- Aplicaciones en Minería de Datos y Procesamiento de Señales.

- **JTP : Esp. César Estrebou**

- Temas: Redes Neuronales Profundas
- Desarrollo de aplicaciones de Machine Learning para Sistemas Embebidos.

- **Ayudante : Ing. Oscar Stanchi**

- Becario doctoral UNLP

Bibliografía

- **Deep Learning with Python, 2nd edition.**

François Chollet.

Manning Publications Co. 2021

- **Neural Networks and Deep Learning**

Michael A. Nilsen

Determination Press. 2015

Semana	Fecha	Teoría	Práctica	Cuestionarios
1	16-ago	Introducción al aprendizaje automático y aprendizaje profundo. Visualización y preprocesamiento.	Lunes 21 feriado <i>(fallecimiento del Gral. San Martín)</i>	C1 - Preprocesamiento y visualización. Perceptrón (habilitado del 24/8 al 6/9)
2	23-ago	Redes Neuronales. Introducción. El perceptrón Matriz de confusión. Precisión y recall.	P1) Preparación de datos para ML con Python. Resolución de problemas linealmente separables	
3	30-ago	Aprendizaje supervisado. Combinador lineal. Descenso del gradiente. Regresión polinomial.	P2.a) Minimización de funciones por gradiente. Resolución de problemas de regresión lineal y polinomial.	C2 - Regresión y Clasificación binaria (habilitado del 7/9 al 20/9)
4	6-sep	Neurona no lineal. Regresión Logística.	P2.b) Resolución de problemas de clasificación binaria.	
5	13-sep	Red Neuronal multiperceptrón. Algoritmo Backpropagation. Funciones de activación.	P3.a) MLP aplicado a la resolución de problemas concretos	C3 - MLP (habilitado del 21/9 al 4/10)
6	20-sep	Validación de modelos predictivos. Matriz de confusión. F-measure. Clasificación binaria. Curva ROC. AUC.	P3.b) validación de los modelos generados	
7	27-sep	Redes Neuronales Profundas. Lenguajes tensoriales. Visualización de la red. Tipos de capas. Funciones de pérdida. Backpropagation.	P4.a) Lenguajes tensoriales y tipos de capas	C4- Redes convolucionales (habilitado del 5/10 al 25/10)
8	4-oct	Redes convolucionales	P4.b) RN Convolucionales	
9	11-oct	Series temporales. Introducción	P6.a) Características de una serie temporal. Preparación de los datos	C5- Series temporales OPCIONAL (habilitado del 26/10 al 13/11)
	18-oct	Expo Ciencia y Tecnología - Miércoles 18-10. Hall de la Facultad		
10	25-oct	Aprendizaje profundo para Series temporales	P6.b) Redes para series temporales	
	30-oct	Consultas de la práctica 6 y consultas para la 1ra. Fecha		
	6-nov	1ra. Fecha de Examen		

Reglamento

□ **ACTIVIDADES**

- ▣ Responder cuestionarios.
- ▣ Examen escrito al final del curso.

□ **NOTA FINAL** del curso

Promedio de

- ▣ Nota promedio de los cuestionarios.
- ▣ Nota del examen final

Reglamento

□ **ACTIVIDADES**

- ▣ Responder cuestionarios.
- ▣ Examen escrito al final del curso.

□ **NOTA FINAL** del curso

Promedio de

- ▣ Nota promedio de los cuestionarios.
- ▣ Nota del examen final

APROBACION DEL CURSO

□ **Promoción**


- ▣ 75% de los cuestionarios aprobados
- ▣ Nota examen escrito ≥ 6 puntos.
- ▣ NOTA FINAL ≥ 6 puntos.

□ **Cursada**

- ▣ 50% de los cuestionarios aprobados
- ▣ Nota examen escrito ≥ 4 puntos.
- ▣ NOTA FINAL ≥ 4 puntos

Inteligencia Artificial

- La **Inteligencia Artificial (IA)** es la inteligencia llevada a cabo por máquinas.
- **RAMAS**
 - ▣ **DEDUCTIVA** (lógica)
 - Sistemas expertos
 - ▣ **INDUCTIVA** (ejemplos)
 - Redes Neuronales
 - Técnicas de Optimización



Inteligencia Artificial

□ La **Inteligencia Artificial (IA)** es la inteligencia llevada a cabo por máquinas.

□ **RAMAS**


▣ **DEDUCTIVA** (lógica)

■ Sistemas expertos

▣ **INDUCTIVA** (ejemplos)

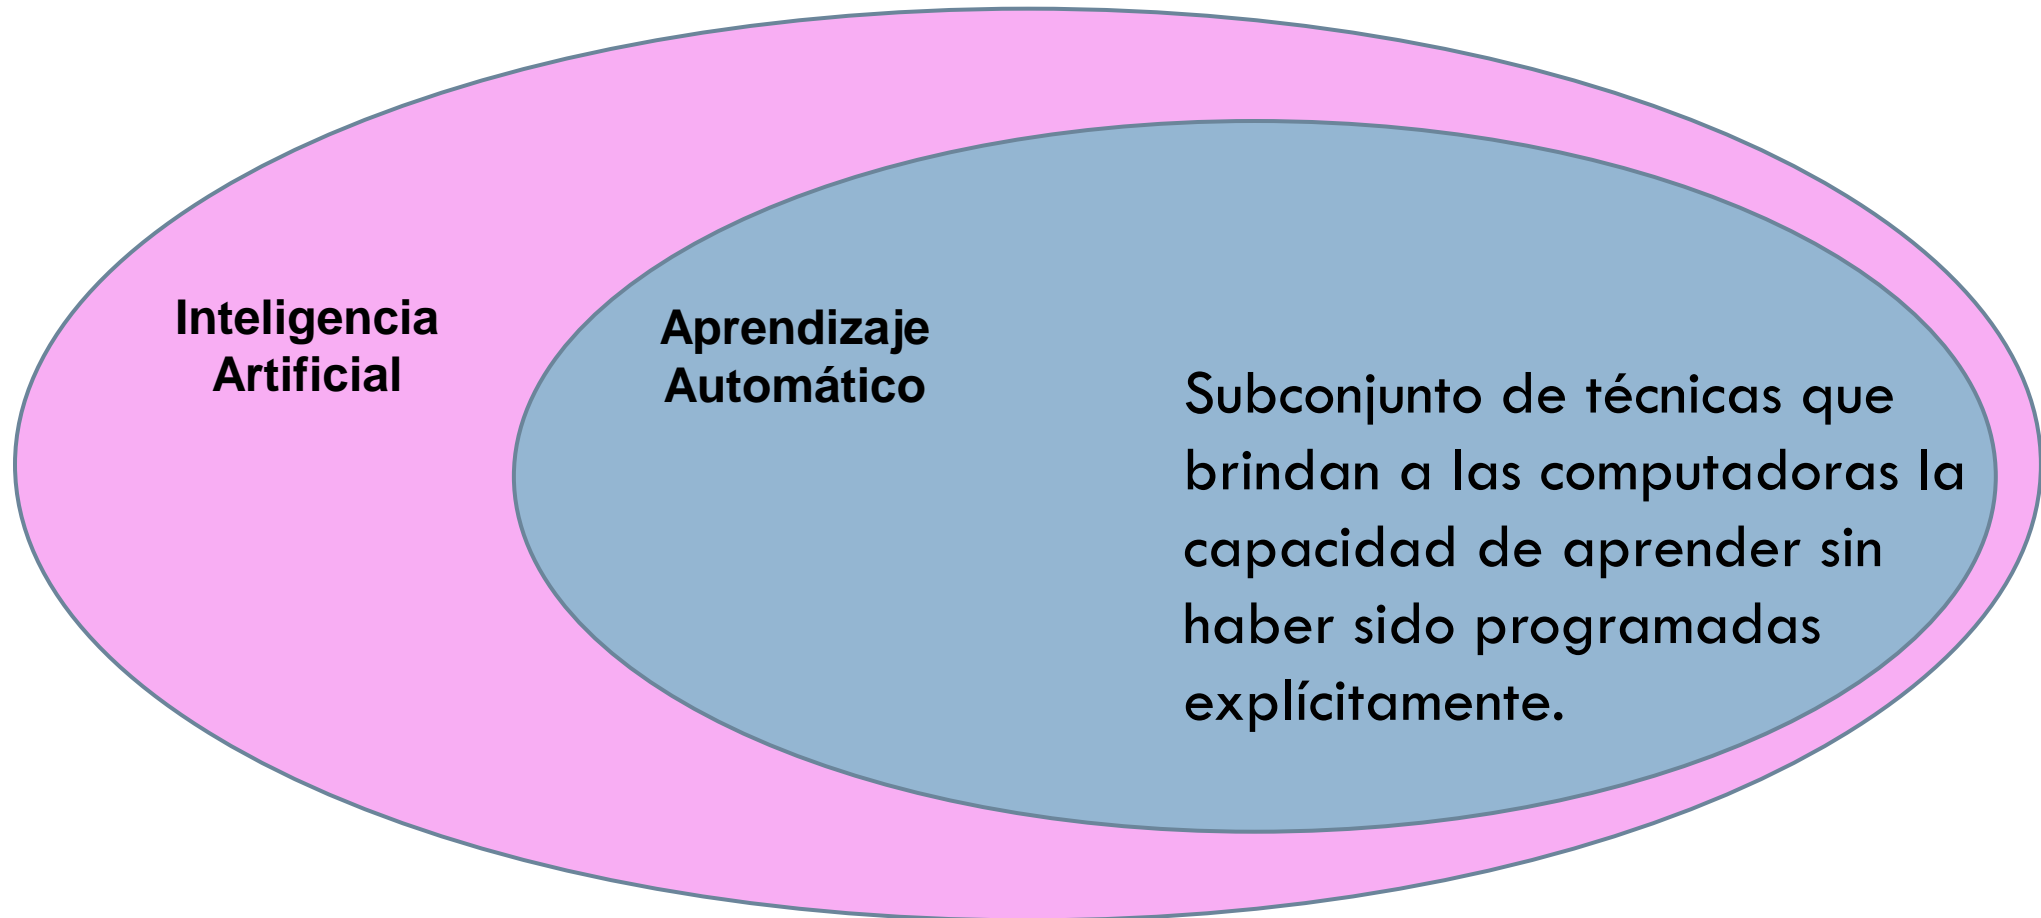
■ Redes Neuronales

■ Técnicas de Optimización

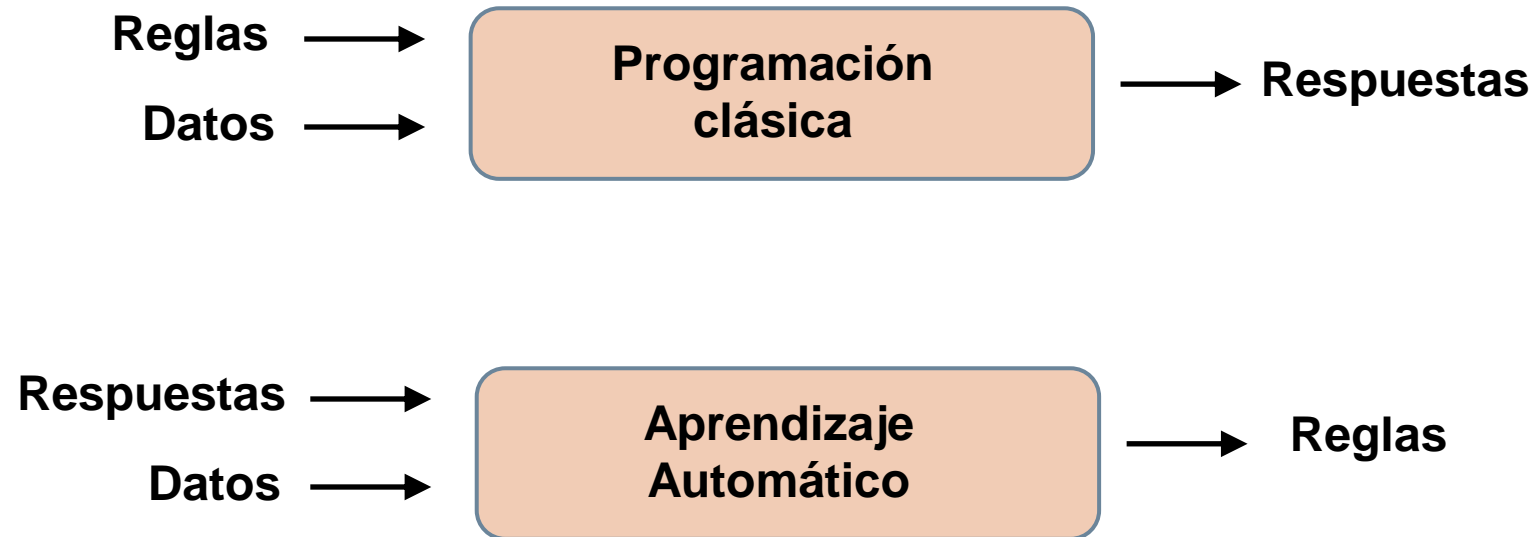


El **aprendizaje automático** pertenece a esta rama

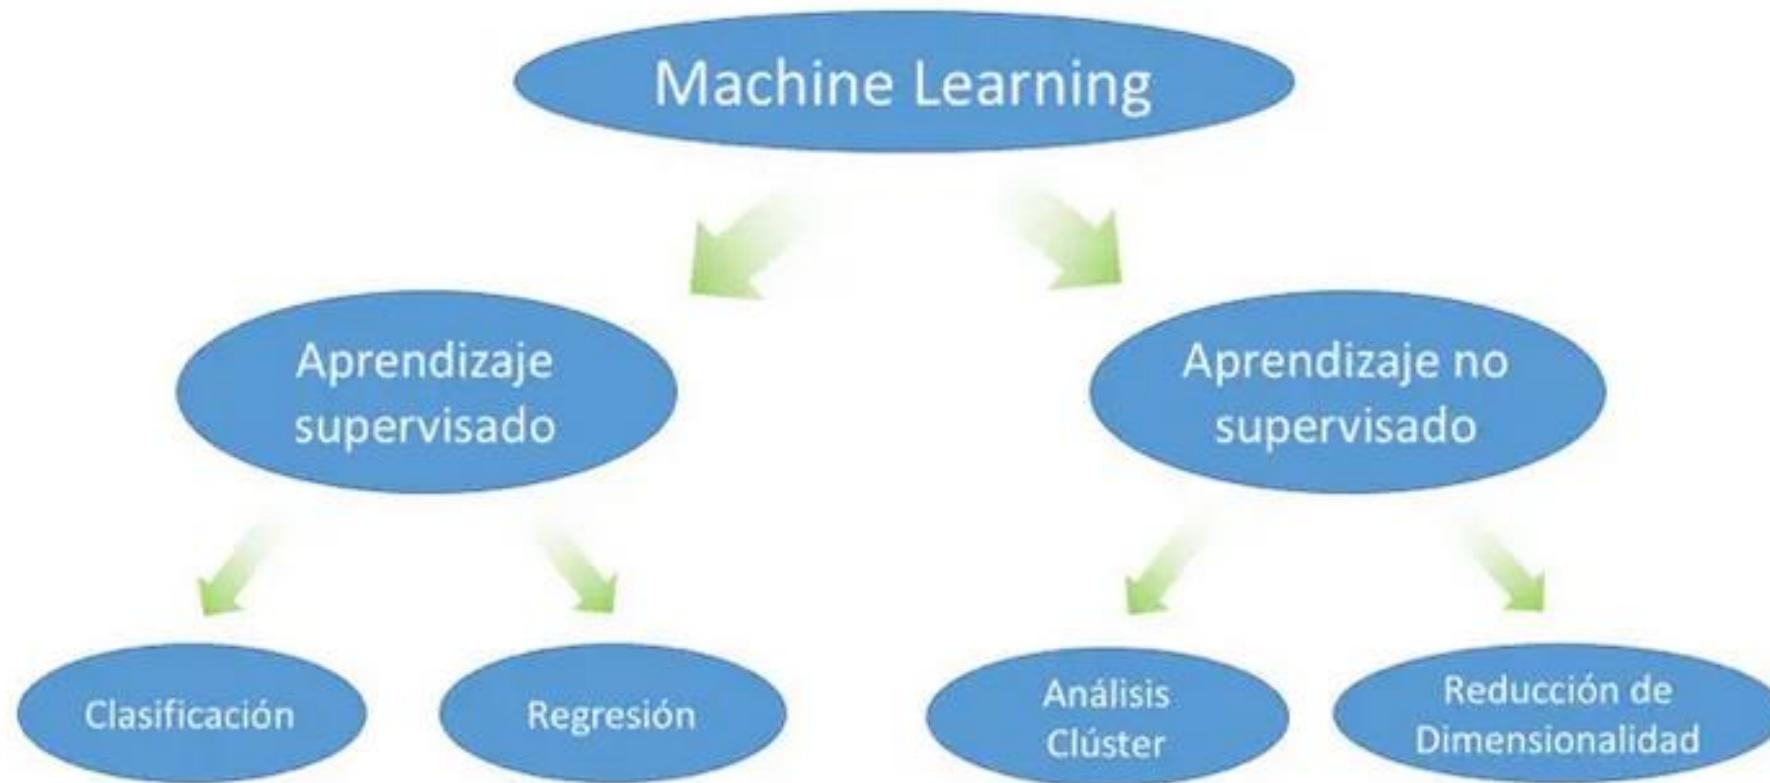
IA y Aprendizaje Automático



Programación clásica y Aprendizaje Automático



Tipos de aprendizaje



Aprendizaje supervisado

GATO



GATO



GATO



ARBOL



ARBOL



CUADERNO



CUADERNO



CUADERNO




GATO



?

Aprendizaje no supervisado



AGRUPAMIENTO

Aprendizaje supervisado

GATO



GATO



GATO



ARBOL



ARBOL



CUADERNO



CUADERNO



CUADERNO



**En este curso trabajaremos con
APRENDIZAJE SUPERVISADO**

GATO




?


Aprendizaje Supervisado

- Según si la respuesta a predecir es **discreta** o **continua** se trata de un problema de **clasificación** o de **regresión** respectivamente.

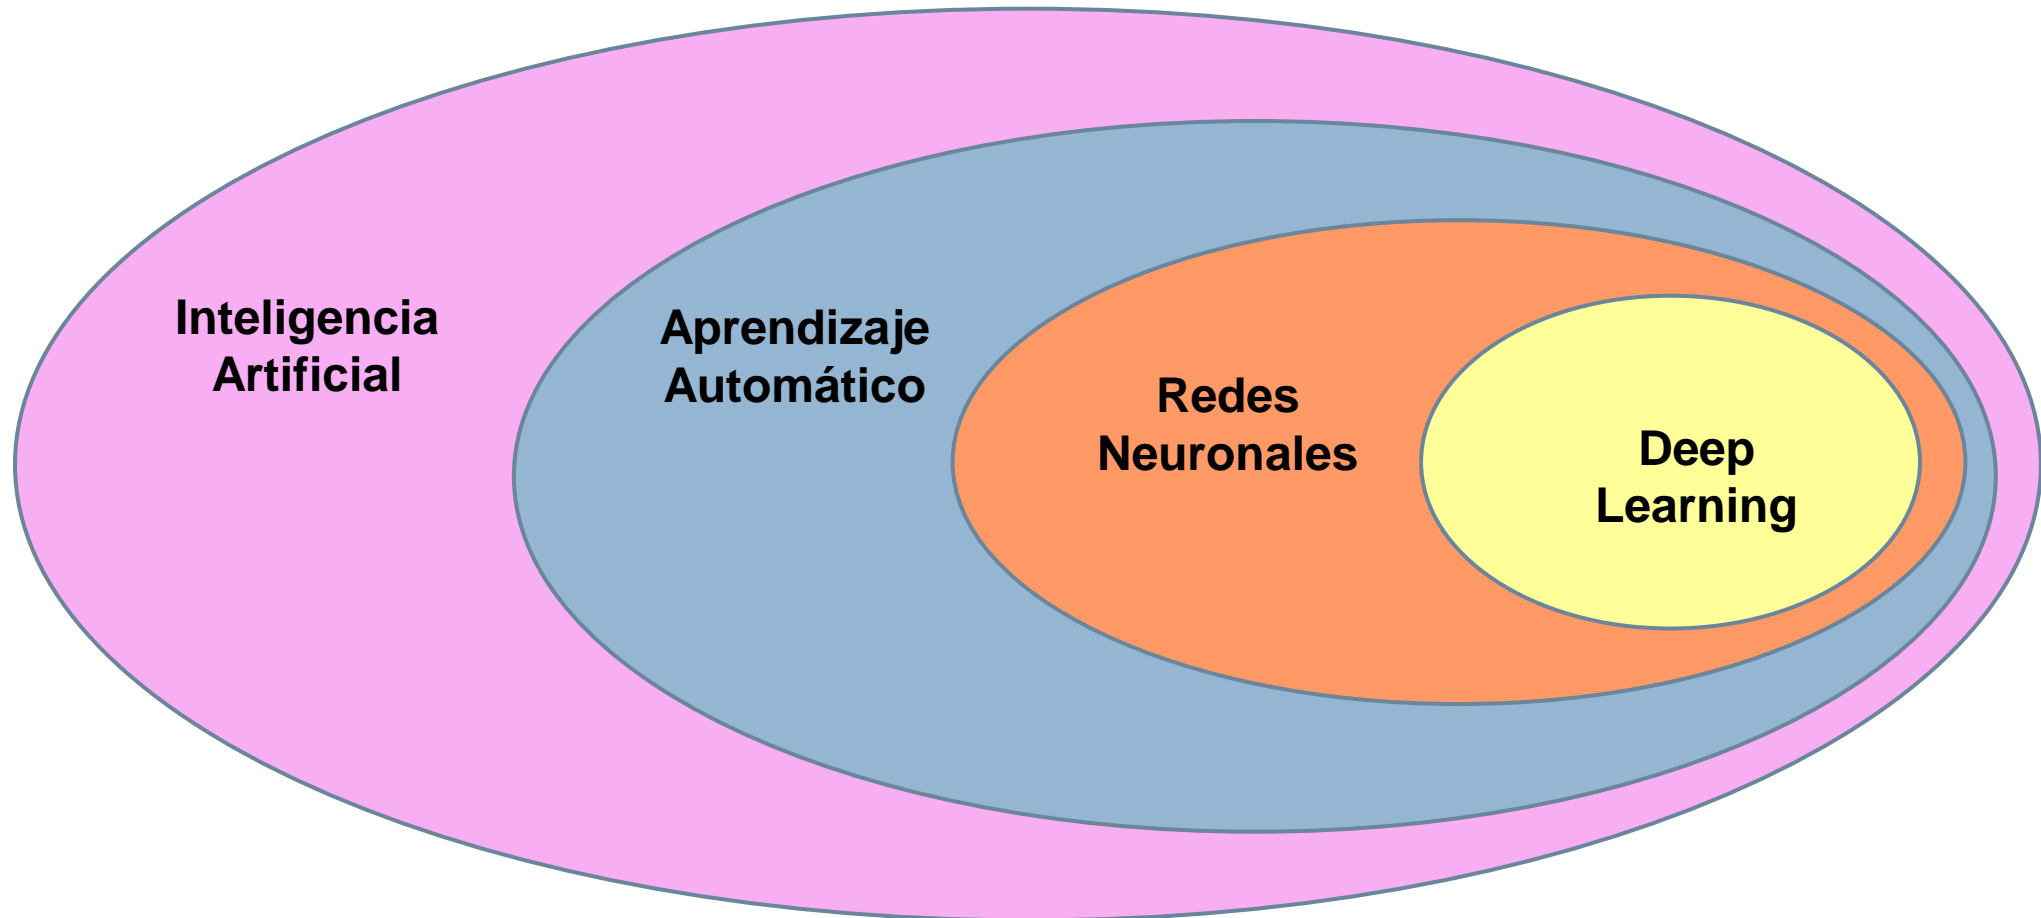
CLASIFICACION



REGRESION



Redes Neuronales y Aprendizaje Profundo



Tareas que pueden resolverse con RN

SUPERVISADO

- **Predicción** de un resultado futuro a partir de los datos disponibles.
 - ▣ Predecir el nivel de seguridad de un vehículo dadas sus características.
 - ▣ Determinar si un mail recibido es spam o no.
 - ▣ Dada la historia clínica de un paciente, predecir la probabilidad de contraer cierta enfermedad.

NO SUPERVISADO


- **Segmentación** de los datos en subgrupos con características similares
 - ▣ Agrupar clientes para determinar perfiles que ayuden a direccionar campañas de marketing.
 - ▣ Caracterizar transacciones comerciales y detectar situaciones anómalas.

Redes Neuronales


- El cerebro humano
 - ▣ Procesa información imprecisa rápidamente.
 - ▣ Aprende sin instrucciones explícitas.
 - ▣ Crea representaciones internas que permiten estas habilidades.
- Las Redes Neuronales Artificiales o simplemente **Redes Neuronales**, buscan emular el comportamiento del cerebro humano.

Neurona biológica

- El cerebro consta de un gran número de elementos (aprox. 10^{11}) altamente interconectados (aprox. 10^4 conexiones por elemento), llamados **neuronas**.




Similitudes entre una neurona biológica y una artificial




Las entradas x_i representan las señales que provienen de otras neuronas y que son capturadas por las dendritas

Similitudes entre una neurona biológica y una artificial



Los pesos W_i son la intensidad de la sinápsis que conecta dos neuronas; tanto x_i como W_i son valores reales.


Similitudes entre una neurona biológica y una artificial



θ es la función umbral que la neurona debe sobrepasar para activarse; este proceso ocurre biológicamente en el cuerpo de la célula.

Red Neuronal Artificial

25



Ejemplo: Clasificación de flores de Iris

- Se dispone de información de 3 tipos de flores Iris




<https://archive.ics.uci.edu/ml/datasets/Iris>

Ejemplo: Clasificación de flores de Iris

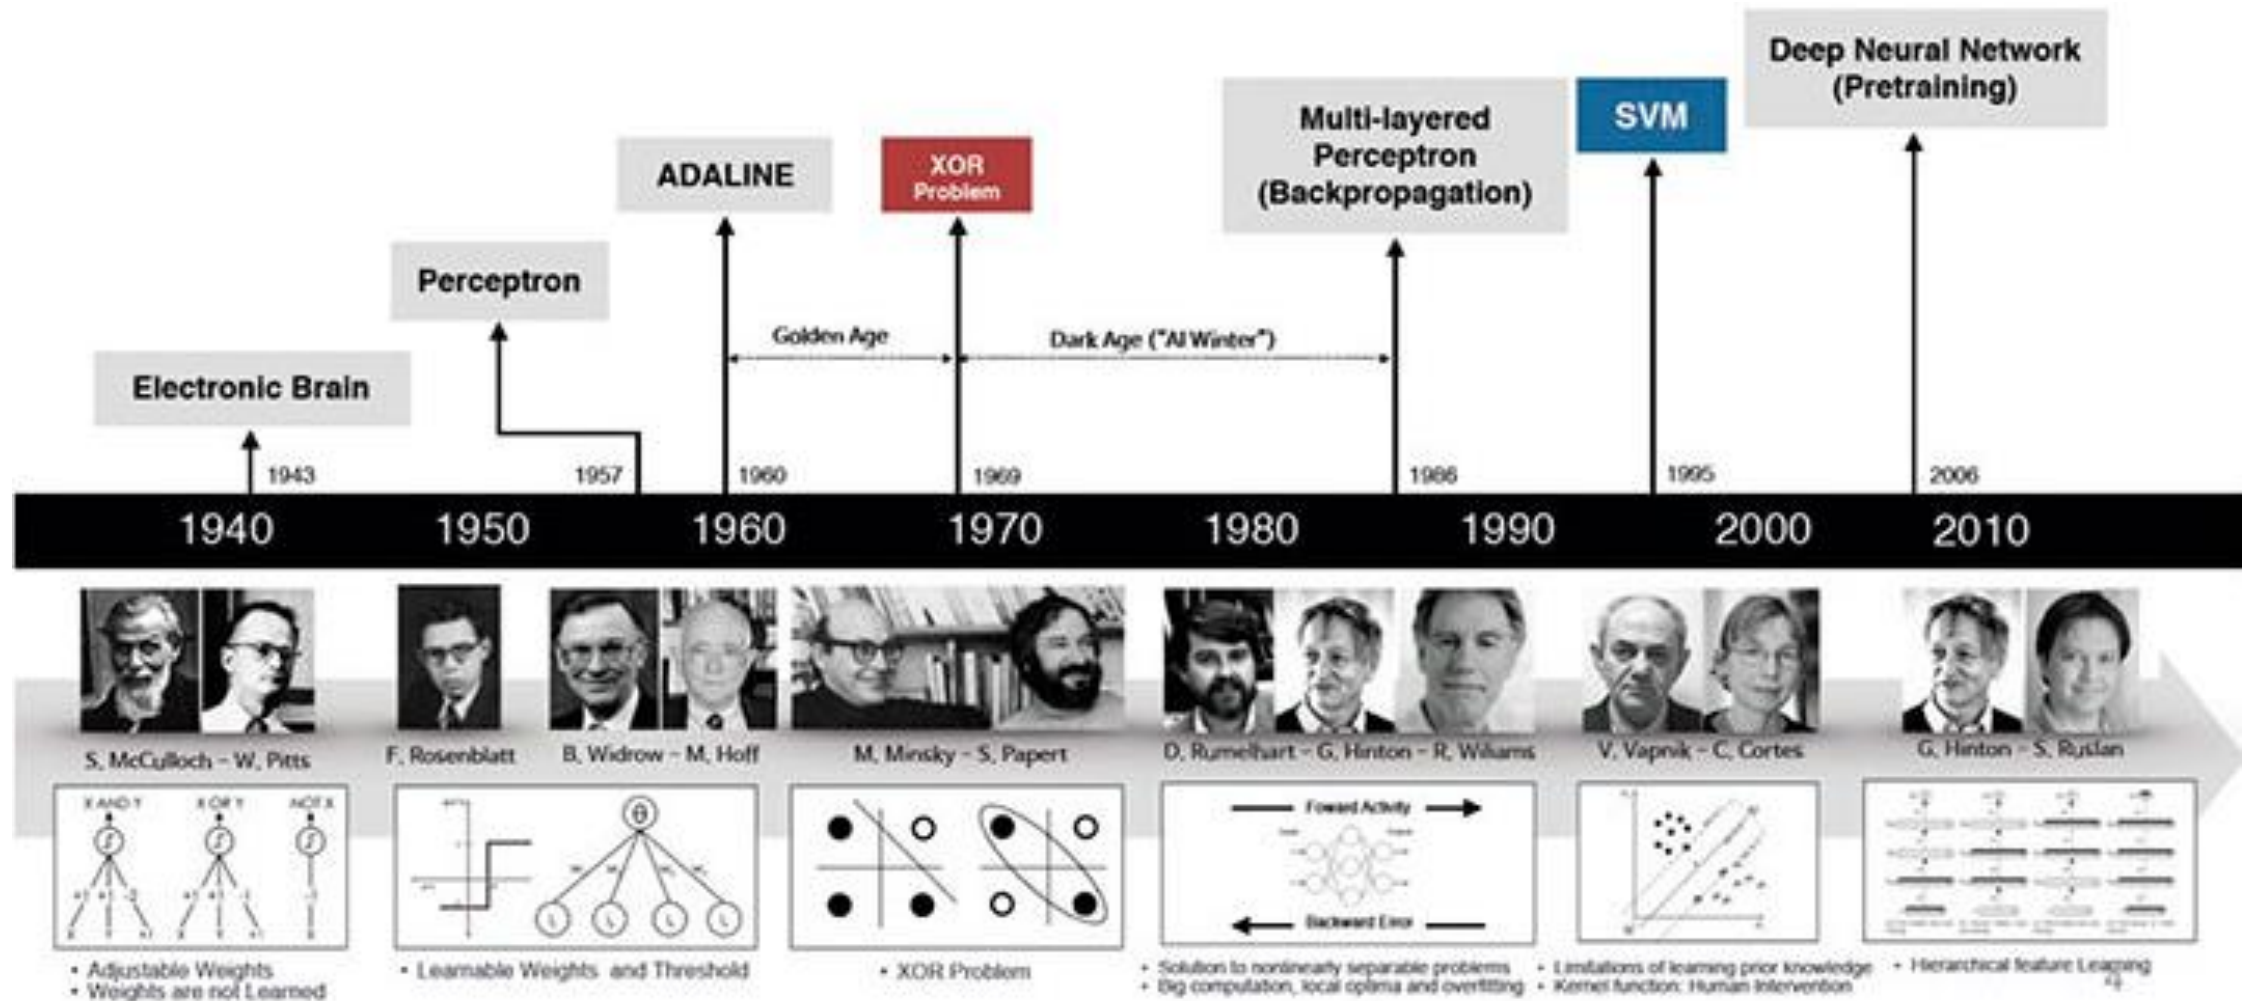
Id	sepalength	sepalwidth	petallength	petalwidth	class
1	5,1	3,5	1,4	0,2	Iris-setosa
2	4,9	3,0	1,4	0,2	Iris-setosa
...
95	5,6	2,7	4,2	1,3	Iris-versicolor
96	5,7	3,0	4,2	1,2	Iris-versicolor
97	5,7	2,9	4,2	1,3	Iris-versicolor
...
149	6,2	3,4	5,4	2,3	Iris-virginica
150	5,9	3,0	5,1	1,8	Iris-virginica

<https://archive.ics.uci.edu/ml/datasets/Iris>

Ejemplo: Clasificación de flores de Iris



Historia de las Redes Neuronales



Sistemas inteligentes



Sistema Inteligente de Transporte – SITBus (billete electrónico) + SAO (control operativo) + SIU (información al usuario)



Análisis de imágenes

- Pinterest incorporó **VisualGraph**



Detector de personas




Detector de bolsos



Detector de faldas

<https://techcrunch.com>

- Empresa **Vicarious** : Inversores Mark Zuckerberg (Facebook), Elon Musk (cofundador de PayPal) buscan determinar las “relaciones de causa y efecto”.
- 2.300 millones de usuarios activos en Facebook generando muchos datos. (Fuente: Data Never Sleeps 2019)




www.adweek.com


- Seguimiento de sus redes sociales para saber
 - ▣ quién está consumiendo sus bebidas
 - ▣ dónde están sus clientes
 - ▣ qué situaciones los incitan a hablar sobre su marca
- Identifica sus productos en fotografías y determina cuando enviar publicidad
- Ahora buscan usar bots para generar anuncios

Representación de los datos

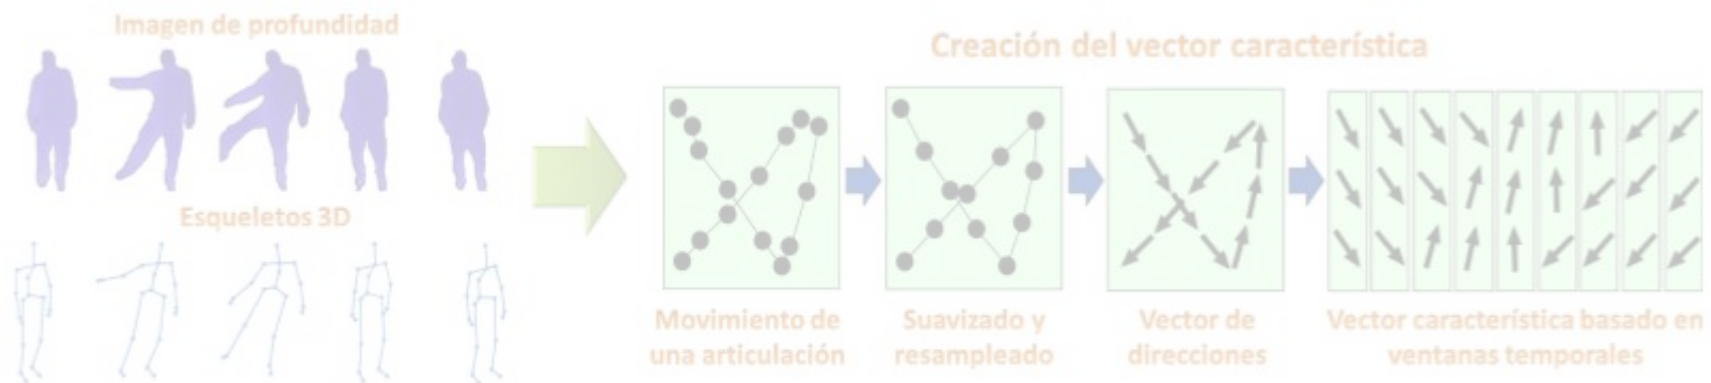
□ Caracterización de rostros




SIFT features - Lowe (2004)



□ Gestos Dinámicos



Redes Neuronales Convolucionales

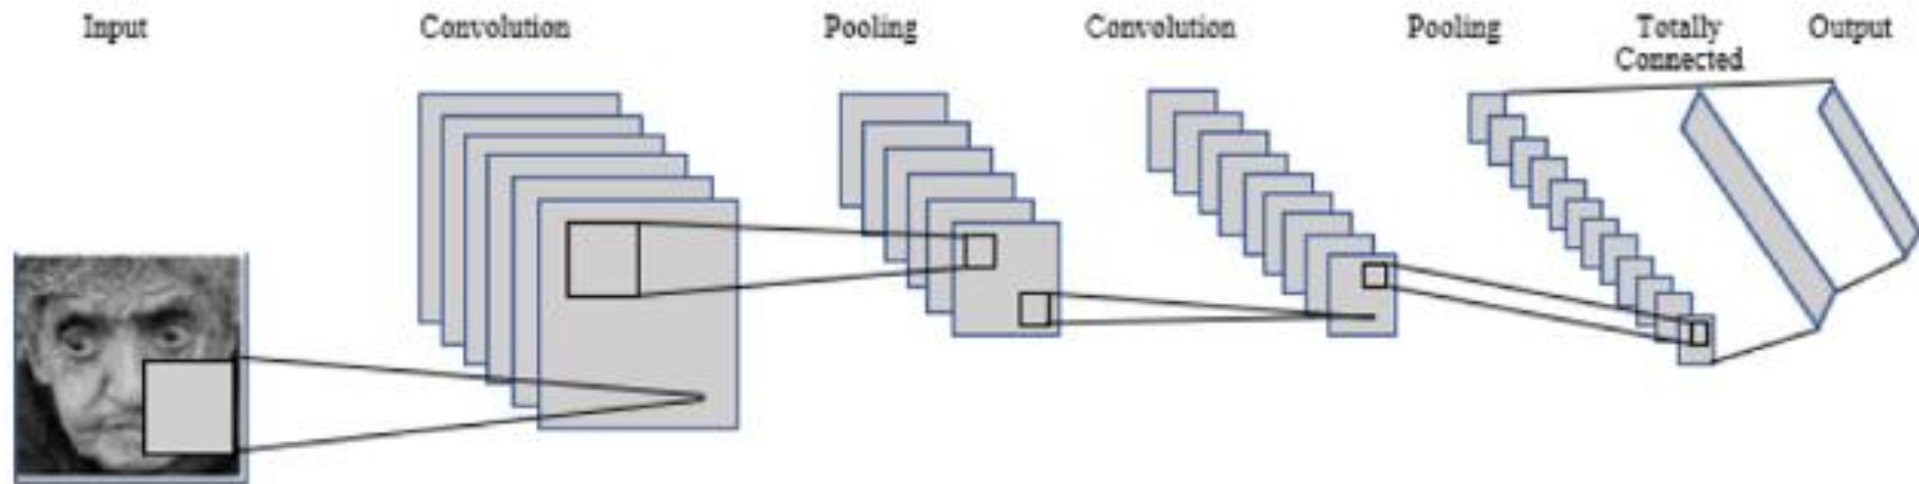


Reconocimiento de expresiones faciales



- ▶ BBDD Facial Expressions in the Wild (+ de 80 mil imágenes. Alegría, sorpresa, tristeza, enojo, miedo y disgusto)
- ▶ Arquitecturas de CNNs : VGG, Inception o ResNet
- ▶ TensorFlow, Keras y PyTorch (Frameworks para Deep Learning)

Expresiones faciales en pacientes con Alzheimer



Castillo-Salazar D. et al. (2020) **Detection and Classification of Facial Features Through the Use of Convolutional Neural Networks (CNN) in Alzheimer Patients.** In: *Human Systems Engineering and Design II. IHSED 2019. Advances in Intelligent Systems and Computing*, vol 1026. Springer.

https://doi.org/10.1007/978-3-030-27928-8_94

Redes Neuronales que generan datos

- 2014 **Redes Generativas Adversarias (GAN)** generan nuevos datos en situaciones en que éstos son limitados.



Redes Neuronales que generan datos

- 2014 □ **Redes Generativas Adversarias (GAN)** generan nuevos datos en situaciones en que éstos son limitados.

<https://dl.acm.org/doi/10.5555/2969033.2969125>


- 2019 □ **Autoencoders Variacionales (VAE)** tienen por objetivo reconstruir los datos de entrada.

- ▣ DeepMind demostró que los VAEs podían superar a las GAN en la generación de caras.


<https://arxiv.org/abs/1906.00446>

Contenido del curso

APRENDIZAJE AUTOMATICO



DEEP LEARNING



Contenido del curso

PARTE I

- Perceptrón
- Combinador Lineal (regresión)
- Neurona no lineal (clasificación)
- Multiperceptrón con aprendizaje backpropagation

PARTE II

- Mejoras al entrenamiento del multiperceptrón.
- Arquitecturas varias
 - ▣ RN convolucionales
 - ▣ Autoencoders
 - ▣ RN recurrentes

Análisis de los datos disponibles

□ Tipos de Variables

- Cuantitativas y cualitativas

□ Descripciones estadísticas

- Medidas de tendencia central
- Medidas de dispersión

□ Gráficos

- Diagrama de barras
- Diagrama de torta
- Histograma
- Diagrama de caja
- Diagrama de dispersión

Tipos de variables


□ **Cuantitativas o numéricas**

- ▣ DISCRETAS (cant. de empleados, cant. de alumnos, etc)
- ▣ CONTINUAS (sueldo, metros cuadrados, beneficios, etc)

□ **Cualitativas o categóricas**

- ▣ NOMINALES: nombran al objeto al que se refieren sin poder establecer un orden (estado civil, raza, idioma, etc.)
- ▣ ORDINALES: se puede establecer un orden entre sus valores (alto, medio, bajo, etc)

- Se busca predecir si el tipo de fármaco que se debe administrar a un paciente afectado de rinitis alérgica es el habitual o no.



- Se dispone de información de pacientes afectados de rinitis alérgica:
 - ▣ Age: Edad
 - ▣ Sex: Sexo
 - ▣ BP (Blood Pressure): Tensión sanguínea.
 - ▣ Cholesterol: nivel de colesterol.
 - ▣ Na: Nivel de sodio en la sangre.
 - ▣ K: Nivel de potasio en la sangre.
 - ▣ Cada paciente ha sido medicado con un único fármaco de entre cinco posibles: DrugA, DrugB, DrugC, DrugX, DrugY.

Ejemplo

DRUG5.CSV

- Drug5.csv contiene 200 muestras de pacientes atendidos previamente

Nro.	Age	Sex	BP	Colesterol	Na	K	Drug
1	23	F	HIGH	HIGH	0,792535	0,031258	drugY
2	47	M	LOW	HIGH	0,739309	0,056468	drugC
3	47	M	LOW	HIGH	0,697269	0,068944	drugC
4	28	F	NORMAL	HIGH	0,563682	0,072289	drugX
5	61	F	LOW	HIGH	0,559294	0,030998	drugY
...
...
...
197	16	M	LOW	HIGH	0,743021	0,061886	drugC
198	52	M	NORMAL	HIGH	0,549945	0,055581	drugX
199	23	M	NORMAL	NORMAL	0,78452	0,055959	drugX
200	40	F	LOW	NORMAL	0,683503	0,060226	drugX

Ejemplo

Leer_Drug5.ipynb

- Drug5.csv contiene 200 muestras de pacientes atendidos previamente

Nro.	Age	Sex	BP	Colesterol	Na	K	Drug
1	23	F	HIGH	HIGH	0,792535	0,031258	drugY
2	47	M	LOW	HIGH	0,739309	0,056468	drugC
3	47	M	LOW	HIGH	0,697269	0,068944	drugC
4	28	F	NORMAL	HIGH	0,563682	0,072289	drugX
5	61	F	LOW	HIGH	0,559294	0,030998	drugY
...

- ¿Cuántos atributos tiene la tabla?
- ¿De qué tipo es cada uno de ellos?

Análisis de los datos disponibles

□ Tipos de Variables

- ▣ Cuantitativas y cualitativas

□ Descripciones estadísticas

- ▣ Medidas de tendencia central
- ▣ Medidas de dispersión

□ Gráficos

- ▣ Diagrama de barras
- ▣ Diagrama de torta
- ▣ Histograma
- ▣ Diagrama de caja
- ▣ Diagrama de dispersión

Descripciones estadísticas básicas

- Identifican propiedades de los datos y destacan qué valores deben tratarse como ruido o valores atípicos

MEDIDAS DE TENDENCIA CENTRAL

- Media
- Mediana
- Moda
- Rango medio

MEDIDAS DE DISPERSION

- Varianza
- Desviación estándar
- Rango
- Cuartiles
- Rango Intercuartil

Descripciones estadísticas básicas

- Identifican propiedades de los datos y destacan qué valores deben tratarse como ruido o valores atípicos

MEDIDAS DE TENDENCIA CENTRAL

- Media
- Mediana
- Moda
- Rango medio

MEDIDAS DE DISPERSION

- Varianza
- Desviación estándar
- Rango
- Cuartiles
- Rango Intercuartil

Análisis de los datos disponibles

□ Tipos de Variables

- ▣ Cuantitativas y cualitativas

□ Descripciones estadísticas


- ▣ Medidas de tendencia central
- ▣ Medidas de dispersión

□ Gráficos


- ▣ Diagrama de barras
- ▣ Diagrama de torta
- ▣ Histograma
- ▣ Diagrama de caja
- ▣ Diagrama de dispersión

Leer_Drug5.ipynb

Atributo Drug - Diagrama de barras




Atributo Drug - Gráfico de Torta



Atributo AGE – Histograma

(Atributo AGE del archivo Drug5_atipicos.CSV)



Media	44.965
--------------	---------------


Desviación	19.145
-------------------	---------------

Minimo	15
---------------	-----------

Maximo	174
---------------	------------

Rango	159
--------------	------------

Diagrama de caja - Ejemplo



- Se consideran **valores atípicos leves** a los que se encuentran a $1.5 \times \text{RIC}$ más allá de los límites de la caja y **atípicos extremos** a los que están más allá de $3 \times \text{RIC}$.

Determine si hay valores atípicos y si son leves o extremos

Cuartiles y RIC del atributo AGE

(Atributo AGE del archivo Drug5_atipicos.CSV)

- Luego de ordenar los valores del atributo AGE deben identificarse los valores que los dividen en cuatro partes iguales.

$$Q_1 = 31$$



$$Q_2 = 45$$



$$Q_3 = 58$$




15	...	31	31	...	43	45	45	45	...	58	58	...	174
1	...	50	51	...	99	100	101	102	...	150	151	...	200

$$RIC = Q_3 - Q_1 = 58 - 31 = 27$$

Diagrama de caja (en construcción)

□ Atributo AGE (archivo Drug5_atipicos.csv)

Minimo	15
Q1	31
Q2	45
Q3	58
Maximo	174




RIC	$Q3 - Q1 = 58 - 31 = 27$
Lim.Inf	$Q1 - 1.5 * RIC = 31 - 1.5 * 27 = -9.5$
Lim.Sup	$Q3 + 1.5 * RIC = 58 + 1.5 * 27 = 98.5$

Hay valores
atípicos?

Diagrama de caja (en construcción)

□ Atributo AGE (archivo Drug5_atipicos.csv)

Minimo	15
Q1	31
Q2	45
Q3	58
Maximo	174




RIC	$Q3 - Q1 = 58 - 31 = 27$
Lim.Inf	$Q1 - 1.5 * RIC = 31 - 1.5 * 27 = -9.5$
Lim.Sup	$Q3 + 1.5 * RIC = 58 + 1.5 * 27 = 98.5$

Diagrama de caja

□ Atributo AGE

Minimo	15
Q1	31
Q2	45
Q3	58
Maximo	174



RIC	$Q3 - Q1 = 27$
Lim.Inf	$Q1 - 1.5 * RIC = -9.5$
Lim.Sup	$Q3 + 1.5 * RIC = 98.5$


Los bigotes indican el rango de los valores de la muestra comprendidos en el intervalo

$$[Q1 - 1.5 * RIC ; Q3 + 1.5 * RIC] = [-9.5, 98.5]$$

Diagrama de caja

□ Atributo AGE

Minimo	15
Bigote Inferior	15
Q1	31
Q2	45
Q3	58
Bigote Superior	74
Maximo	174



- Los valores de AGE que pertenezcan a $[-50; -9.5)$ o $(98.5; 139]$ se considerarán **atípicos leves**.
- Los valores del atributo AGE inferiores a -50 o superiores a 139 se considerarán **atípicos extremos**.

Histograma y diagrama de caja

(Atributo AGE archivo Drug5_atipicos.CSV)





Diagrama de Dispersión


- Consiste en dibujar pares de valores (x_i, y_i) medidos de la v.a. (X,Y) en un sistema de coordenadas



Entre X e Y no hay ninguna relación funcional

Diagrama de Dispersión


- Consiste en dibujar pares de valores (x_i, y_i) medidos de la v.a. (X,Y) en un sistema de coordenadas



Entre X e Y podría existir un relación funcional que corresponde a una parábola

Diagrama de Dispersión

- Consiste en dibujar pares de valores (x_i, y_i) medidos de la v.a. (X, Y) en un sistema de coordenadas



Entre X e Y existe una **relación lineal**. Este es el tipo de relación que nos interesa

Relación entre atributos numéricos

- Al momento de construir un modelo resulta de interés saber si dos atributos numéricos se encuentran linealmente relacionados o no. Para ello se usa el **coeficiente de correlación lineal**.




Diagrama de dispersión entre la longitud y el ancho del pétalo de una flor.

Coeficiente de correlación lineal


INTERPRETACION

- Si $0.5 \leq \text{abs}(\text{Corr}(A,B)) < 0.8$ se dice que A y B tienen una correlación lineal débil.
- Si $\text{abs}(\text{Corr}(A,B)) \geq 0.8$ se dice que A y B tienen una correlación lineal fuerte
- Si $\text{abs}(\text{Corr}(A,B)) < 0.5$ se dice que A y B no están correlacionados linealmente. Esto NO implica que son independientes, sólo que entre ambos no hay una correlación lineal.

Ejemplo

Correlacion_Iris.ipynb

- El valor del **coeficiente de correlación lineal** entre los atributos PETALLENGTH y PETALWIDTH es **0.96**



Ejemplo

Correlacion_Iris.ipynb

- El valor del **coeficiente de correlación lineal** entre los atributos SEPALLENGTH y SEPALWIDTH es **-0.11**





Diagrama de dispersión

(atributos K y Na del archivo Drug5.csv)



$\text{Corr}(K, Na) = 0.017$

Resumen

□ Tipos de aprendizaje

- ▣ Supervisado
- ▣ No supervisado

□ Tipos de Variables

- ▣ Cuantitativas y cualitativas

□ Descripciones estadísticas

- ▣ Medidas de tendencia central
- ▣ Medidas de dispersión

□ Gráficos

- ▣ Diagrama de barras
- ▣ Diagrama de torta
- ▣ Histograma
- ▣ Diagrama de caja
- ▣ Diagrama de dispersión
Coeficiente de correlación lineal